



基于物理信息神经网络的盾构隧道诱发地表沉降预测

张子龙 潘秋景 仇文岗 黄阜

PREDICTION OF SURFACE SETTLEMENTS INDUCED BY SHIELD TUNNELLING USING PHYSICS-INFORMED NEURAL NETWORKS

ZHANG Zi-long, PAN Qiu-jing, ZHANG Wen-gang, HUANG Fu

在线阅读 View online: <https://doi.org/10.6052/j.issn.1000-4750.2022.04.0369>

您可能感兴趣的其他文章

Articles you may be interested in

盾构下穿铁路碎石道床沉降规律及施工参数控制

THE SETTLEMENT LAW OF RAILWAY BALLAST BEDS TRAVERSED BY A SHIELD TUNNEL AND THE CONTROL OF SHIELD CONSTRUCTION PARAMETERS

工程力学. 2019, 36(S1): 222-228 <https://doi.org/10.6052/j.issn.1000-4750.2018.04.S044>

软土地区侧压损失对盾构隧道受力及变形的影响

INFLUENCE OF LATERAL PRESSURE LOSS ON THE FORCE AND DEFORMATION OF SHIELD TUNNEL IN SOFT SOIL AREA

工程力学. 2019, 36(5): 148-156,175 <https://doi.org/10.6052/j.issn.1000-4750.2018.04.0216>

盾构隧道环间接头弯曲状态非线性研究

STUDY ON BENDING STATE NONLINEARITY OF SHIELD-TUNNEL RING JOINTS

工程力学. 2018, 35(11): 35-44 <https://doi.org/10.6052/j.issn.1000-4750.2017.08.0624>

考虑剪切作用的盾构隧道管片接头力学模型研究

RESEARCH OF MECHANICAL MODEL OF SHIELD TUNNEL'S SEGMENT JOINT UNDER THE SHEARING EFFECT

工程力学. 2020, 37(3): 157-166 <https://doi.org/10.6052/j.issn.1000-4750.2019.04.0213>

荷载裂缝几何形态对管片外排钢筋锈层分布的影响

EFFECT OF GEOMETRY FORM OF LOAD CRACK ON RUST LAYER DISTRIBUTION OF OUTSIDE STEEL IN SEGMENT

工程力学. 2020, 37(4): 118-128 <https://doi.org/10.6052/j.issn.1000-4750.2019.06.0307>

基于长短时记忆神经网络的大跨拱桥温度-位移相关模型建立方法

METHOD OF MODELING TEMPERATURE-DISPLACEMENT CORRELATION FOR LONG-SPAN ARCH BRIDGES BASED ON LONG SHORT-TERM MEMORY NEURAL NETWORKS

工程力学. 2021, 38(4): 68-79 <https://doi.org/10.6052/j.issn.1000-4750.2020.05.0323>



订阅号：面向读者



订阅号：面向作者

扫码关注微信公众号，获得更多资讯信息

文章编号: 1000-4750(2024)04-0161-13

基于物理信息神经网络的盾构隧道 诱发地表沉降预测

张子龙¹, 潘秋景^{1,2}, 仇文岗³, 黄 阜⁴

(1. 中南大学土木工程学院, 湖南, 长沙 410075; 2. 中南大学隧地工程研究中心, 湖南, 长沙 410075;

3. 重庆大学土木工程学院, 重庆 400045; 4. 长沙理工大学土木工程学院, 湖南, 长沙 410004)

摘 要: 地表沉降是城市复杂环境下盾构隧道施工重点关注的问题。传统机器学习方法在预测隧道施工诱发地表沉降时忽略了其内在的物理机理, 存在对训练样本需求量较大的弊端。基于深度神经网络 (deep neural networks, DNN) 对 Verruijt-Booker 解的围岩位移因子进行修正, 构建地表沉降与隧道开挖面空间位置的关联。将修正后的 Verruijt-Booker 解的物理方程耦合至另一并行的 DNN 框架中, 构建数据-物理双驱动的物理信息神经网络模型 (physics-informed neural networks, PINN), 从而约束神经网络在满足物理机制的空间中进行训练。算例分析的结果表明: 在同等配置的条件下, 提出的 PINN 模型的预测效果显著优于单一数据驱动的传统 DNN 模型, 其外推泛化性能得到显著提升。工程应用的结果表明: PINN 模型可以利用施工前期的实测数据, 准确预测后续施工过程中开挖面在不同位置时监测断面的地表沉降值。提出的方法有助于提高盾构隧道施工过程中地表沉降控制的智慧化程度, 可为工程的潜在风险及施工决策提供预警和指导。

关键词: 盾构隧道; 地表沉降; 物理信息神经网络; 物理机理; 数据物理双驱动

中图分类号: TU231 **文献标志码:** A **doi:** 10.6052/j.issn.1000-4750.2022.04.0369

PREDICTION OF SURFACE SETTLEMENTS INDUCED BY SHIELD TUNNELLING USING PHYSICS-INFORMED NEURAL NETWORKS

ZHANG Zi-long¹, PAN Qiu-jing^{1,2}, ZHANG Wen-gang³, HUANG Fu⁴

(1. School of Civil Engineering, Central South University, Changsha, Hu'nan 410075, China;

2. Tunnel and Underground Engineering Research Center of Central South University, Changsha, Hu'nan 410075, China;

3. School of Civil Engineering, Chongqing University, Chongqing 400045, China;

4. School of Civil Engineering, Changsha University of Science & Technology, Changsha, Hu'nan 410004, China)

Abstract: Tunnelling-induced surface settlement is a significant concern due to the complexity of urban environment. For the prediction of surface settlements, traditional machine learning methods ignore the underlying physical mechanism, resulting in the requirement of excessive training samples. Based on the framework of a DNN, the classical Verruijt-Booker solution is modified to connect tunnelling-induced surface settlements with the position of a tunnel face. The modified solution is integrated into a paralleled DNN framework to build the data-driven and physics-informed PINN model, in which the physical mechanism can constrain the neural network. The results of illustrative examples show that: compared to the traditional DNN

收稿日期: 2022-04-26; 修改日期: 2022-07-29

基金项目: 国家自然科学基金青年科学基金项目(52108388); 国家自然科学基金面上项目(52078086, 51878074); 湖湘青年英才基金项目(2021RC3015); 湖南省自然科学基金面上项目(2021JJ30714); 湖南省自然科学基金青年科学基金项目(2022JJ40611)

通信作者: 潘秋景(1987—), 男, 湖南人, 教授, 博士, 主要从事盾构隧道掘进力学与智能决策的研究 (E-mail: qiuqing.pan@csu.edu.cn).

作者简介: 张子龙(1994—), 男, 河南人, 博士生, 主要从事岩土与地下工程稳定性的研究 (E-mail: zilongzhang@csu.edu.cn);

仇文岗(1983—), 男, 河北人, 教授, 博士, 博导, 主要从事岩土工程大数据与机器学习的研究 (E-mail: cheungwg@126.com);

黄 阜(1985—), 男, 湖南人, 教授, 博士, 主要从事隧道工程稳定性的研究 (E-mail: hfcsu0001@163.com).

model, the generalization capability of a PINN model has apparently increased. The results of engineering applications show that: based on the monitoring data at the early stage of a shield tunnel project, the PINN model can accurately predict the surface settlement in the process subsequent to construction; in addition, it increases the intelligence of surface settlement control, which can provide early warnings for potential risks and construction suggestions.

Key words: shield tunnel; surface settlement; PINN; physical mechanism; data-driven and physics-informed

地铁的通行释放了城市的地面空间,在很大程度上缓解了日益增加的人口和车辆给城市交通系统带来的压力。盾构法以其自动化程度高、安全快速、环境友好等特点被广泛应用于地铁隧道的施工中。在城市建筑物密集、人口稠密的复杂环境下修建地铁隧道时需严格控制对周边环境的影响。因此,科学合理地预测地层变形对保障施工安全具有重要意义。此外,城市轨道交通作为“十四五”规划中“新基建”的重要一环,如何使地铁建设朝着智能绿色、安全可靠的现代化、智慧化方向发展是需要进一步研究的课题。

当前有关盾构施工诱发地表沉降的研究方法主要有:经验公式法^[1-3]、解析法^[4-8]、数值模拟^[9-11]、模型试验^[12-13]、机器学习^[14-16]等。以 Peck 公式^[1]及其修正形式^[3]为代表的经验公式法可以反映地表沉降的一般形态,但需要基于实测资料和地域特性并结合具体的施工方法才能得到比较合理的预测结果^[2]。解析法的理论推导过程复杂,且大多忽视了地层变形是一个动态的过程,导致其工程应用性较差。数值模拟可以最大程度地描述实际施工过程,被广泛应用于盾构施工诱发地层变形的分析中^[10-11],但也存在输入参数过多、参数不明确、计算成本较高等缺点。模型试验^[12-13]对于揭示沉降变形的规律及演变机理有重要价值,但由于试验成本较高,试验结果与工程实际差距较大,对工程的指导相对有限。

伴随着计算机和人工智能技术的发展,以机器学习方法为代表的代理模型在岩土工程和隧道工程领域展现了广阔的应用前景^[17-22]。CHEN 等^[14]对反向传播神经网络、径向基函数神经网络及广义回归神经网络在预测盾构隧道施工诱发地表沉降方面的性能进行了对比,以长沙地铁 4 号线的工程实测数据为样本进行了训练和验证,表明了广义回归神经网络的预测结果与实测结果有较强的相关性。林荣安等^[23]提出了一种粗糙集和支持向量机耦合的算法 (RS-SVR),实现了对上软下硬地质条件下盾构施工诱发地表沉降的准确预

测。陈仁朋等^[24]对反向传播神经网络 (BPNN) 和随机森林算法 (RF) 在预测地表沉降上的准确性进行了对比,以粒子群算法优化 BPNN 和 RF 中的超参数以提高其鲁棒性,结果表明 RF 算法具有更优的预测性能。FREITAG 等^[15]借助循环神经网络和正交分解法预测了盾构隧道掘进产生的地表沉降场。不可否认,上述机器学习方法提升了地表沉降预测的效率,但需要借助大量的训练样本,而实际工程的复杂性难以保证充足的训练数据。究其原因上述模型仅依靠数据驱动建立输入与输出之间的非线性映射关系,忽视了隧道施工与地层响应之间的物理机理,导致其泛化能力差,过分依赖大数量训练样本的弊端^[25]。

近年来,RAISSI 等^[26]提出了物理信息深度神经网络 (PINN),颠覆了传统机器学习方法的“黑箱”工具属性,PINN 的巧妙之处在于可以集成研究对象内在的物理规律,在处理流体力学、量子力学和计算力学等问题上展现了强大的计算能力。不仅如此,PINN 在对未知物理量的反演问题上也逐渐崭露头角^[27]。作为一种新兴的深度学习方法,虽然在处理力学问题上已引起了较多的关注^[28-29],但其工程应用的潜力有待进一步开发。盾构隧道施工诱发地层变形的过程显然满足一定的物理力学机理,这也是解析法和以有限元为代表的数值模拟法的理论基础。因此,将盾构施工诱发地表沉降的物理机理耦合至深度学习框架,结合已有的工程实测数据,构建数据-物理双驱动的 PINN 预测模型,以期对盾构施工诱发地表沉降的预测提供一种新的、有效的解决途径。

本文基于 Verruijt 和 Booker 提出的隧道开挖诱发地层变形的解析模型,以深度神经网络对 Verruijt-Booker 解的围岩位移因子进行修正,从而建立地表沉降与开挖面空间位置的关联。将修正后的物理控制方程耦合至另一并行的深度神经网络框架中,构建用以预测盾构施工诱发地表沉降的 PINN 模型。以施工前期一定数量的实测数据为训练样本,预测后续施工过程开挖面处于不同位

置时的围岩位移因子, 控制方程的物理信息通过 PINN 损失函数中的物理残差项进行约束, 通过迭代优化, 可以实现对工程后期施工过程中开挖面处在不同位置时监测断面地表变形的预测。研究表明: 预测得到的地表沉降曲线与工程实测数据吻合较好, PINN 相较于传统 DNN 方法显著降低了对训练样本的需求量, 泛化性能显著提升; 提出的方法有助于提高盾构隧道施工中地表沉降安全控制的智慧化程度, 可为工程的潜在风险和施工决策提供预警和指导。

1 物理力学基础

1.1 半无限空间隧道诱发地层变形的解析解

半无限空间隧道诱发地层位移的解析解目前限于线弹性范围^[5, 8, 30], 经典的 Verruijt-Booker 解提供了一个简洁合理的解答^[5], 在合理地确定围岩位移因子 u_r 和 u_e 后, 即可得到符合工程实际情况的地表沉降预测值^[31-32]。

图 1 给出了 Verruijt-Booker 解中两种围岩位移因子的示意图。其中: u_r 为隧道开挖过程中地层损失所引起的均匀径向位移; u_e 为由各向异性初始应力引起的隧道轮廓椭圆化变形。基于上述假设, 可在 (x, z) 空间内定义在 $(0, h)$ 和 $(0, -h)$ 区间点的弹性理论奇异解^[30], 如图 2 所示, 得到隧道及其映像在 x 和 z 方向的位移表达式为:

$$u_x = -u_r r^3 x \left(\frac{1}{r_1^2} + \frac{1}{r_2^2} \right) + u_e r^3 x \left(\frac{x^2 - kz_1^2}{r_1^4} + \frac{x^2 - kz_2^2}{r_2^4} \right) \quad (1)$$

$$u_z = -u_r r^3 \left(\frac{z_1}{r_1^2} + \frac{z_2}{r_2^2} \right) + u_e r^3 \left[\frac{z_1(kx^2 - z_1^2)}{r_1^4} + \frac{z_2(kx^2 - z_2^2)}{r_2^4} \right] \quad (2)$$

式中: $k = \nu/(1 + \nu)$; $z_1 = z - h$; $z_2 = z + h$ 。




图 1 隧道卸载引起的地层损失和椭圆化变形

Fig. 1 Ground loss and ovalization of a tunnel

此时, 在自由面 $z = 0$ 处会出现一个非零的法向应力。由于奇异解严格的对称性, 需在自由面处施加一个大小相等方向相反的法向力, 从而得到的位移解为:

$$u_x = -\frac{2u_r r^3 x}{m} \left(\frac{1}{r_2^2} - \frac{2mzz_2}{r_2^4} \right) - \frac{4u_e r^3 xh}{1+m} \left[\frac{z_2}{r_2^4} + \frac{mz(x^2 - 3z_2^2)}{r_2^6} \right] \quad (3)$$

$$u_z = \frac{2u_r r^3}{m} \left[\frac{(m+1)z_2}{r_2^2} - \frac{mz(x^2 - z_2^2)}{r_2^4} \right] - 2u_e r^3 h \left[\frac{(x^2 - z_2^2)}{r_2^4} + \frac{m}{m+1} \frac{2zz_2(3x^2 - z_2^2)}{r_2^6} \right] \quad (4)$$

式中, $m = 1/(1 - 2\nu)$ 。地层位移 u_x 、 u_z 的最终解即为式 (1) 和式 (3), 式 (2) 和式 (4) 的和。




图 2 奇异点及其映像

Fig. 2 A singularity and its image

在自由表面 $z = 0$ 处, 可得地表沉降值为:

$$u_z|_{z=0} = 2u_r r^3 \frac{(m+1)}{m} A - 2u_e r^3 B \quad (5)$$

其中:

$$A = \frac{h}{(x^2 + h^2)} \quad (6)$$

$$B = \frac{h(x^2 - h^2)}{(x^2 + h^2)^2} \quad (7)$$

在求解得到位移以后, 相应的应力和应变分量即可根据弹性力学的基本原理求解得到。半无限空间隧道诱发沉降变形的控制方程总结为:

$$\sigma_{ij,j} - f_i = 0, \sigma_{ij} = \lambda \delta_{ij} \varepsilon_{kk} + 2\mu \varepsilon_{ij}, \varepsilon_{ij} = \frac{1}{2}(u_{i,j} + u_{j,i}) \quad (8)$$

式中: σ_{ij} 和 ε_{ij} ($i, j = x, z$) 分别为应力和应变张量; 下标逗号表示偏导; f_i 为体力; δ_{ij} 为克罗内克函数; λ 和 μ 为拉梅常数, 可通过下式计算得到:

$$\lambda = \frac{Ev}{(1 + \nu)(1 - 2\nu)} \quad (9)$$

$$\mu = \frac{E}{2(1 + \nu)} \quad (10)$$

1.2 围岩的纵向变形

如前所述, Verruijt-Booker 解可以预测横断面的地层变形, 准确程度依赖于假定的围岩位移因子 u_r 和 u_e 的取值。在 Verruijt-Booker 解中未建立

位移因子与开挖面掘进位置的关系。实际上,盾构掘进过程中,监测断面的地层变形和围岩位移因子随开挖面掘进位置的不同而变化。因此,确定开挖面在不同位置时 Verruijt-Booker 解的围岩位移因子,即可构建监测断面地层变形与开挖面掘进位置的关系。

隧道开挖过程中围岩变形的空间效应如图 3 所示,其中横坐标表示开挖面掘进位置,纵坐标表示拱顶位移; Verruijt-Booker 解中围岩的拱顶位移为 u_r 和 u_e 的和,在此用 u_s 进行表示; u_∞ 表示开挖面距监测断面无穷远处时的拱顶位移;开挖面处于 y_i 时的拱顶位移为 $u_s(y_i)$, 此时有 $u_s(y_i) = u_r(y_i) + u_e(y_i)$ 。在确定 $u_r(y_i)$ 和 $u_e(y_i)$ 后,再根据 Verruijt-Booker 解便可确定开挖面于 y_i 处时监测断面的地层变形。




图 3 围岩位移与开挖面空间位置的关系

Fig. 3 Relation between the displacement of surrounding rock and the position of excavation surface

基于上述思路,本文以 DNN 修正 Verruijt-Booker 解中的围岩位移因子 u_r 和 u_e ,建立地表沉降与开挖面空间位置的关联,即图 3 所示关系。修正后的围岩位移因子表示为 $\eta = \{u_r(y_i), u_e(y_i)\}$, η 将通过 DNN 和并行的 PINN 共同训练得到,具体的网络结构在下文的工程应用小节进行了详述。修正后可表征空间效应的地表沉降解析表达式为:

$$u_z|_{z=0} = 2u_r(y)r^3 \frac{m+1}{m} A - 2u_e(y)r^3 B \quad (11)$$

2 PINN 深度神经网络架构

物理问题往往需要满足其内在规律,如能量守恒、动量守恒。对于隧道开挖引起的地表沉降而言,也需要满足一定的应力-应变关系。基于数据-物理双驱动的深度学习方法,是将研究问题所需满足的物理机制耦合至深度神经网络框架中,

物理信息通过损失函数中的物理残差项进行表达,以此来惩罚不满足相应物理条件的解,约束神经网络在满足物理关系的空间中训练,从而降低对训练样本数据量的过度需求,提高模型的泛化性能。图 4 为 PINN 的基本框架图。




图 4 PINN 框架图

Fig. 4 Framework of a physics-informed neural network

深度前馈神经网络包含输入层、隐含层和输出层。隐含层中每一层神经元的输出作为下一层神经元的输入,信号由输入层向输出层单向传播,此单向传播过程可以表示为:

$$a_i^l = \sigma(z_i^l) = \sigma(w^l \cdot a_i^{l-1} + b^l) \quad (12)$$

式中:上标 l 为神经网络的层数;下标 i 为神经元的索引; a_i^l 为第 l 层中全部 i 个神经元的输出集合; z_i^l 为第 l 层中全部 i 个神经元的输入集合; w^l 为第 l 层中所有权重的集合; b^l 为第 l 层中所有偏置的集合; $\sigma(z_i^l)$ 为激活函数,本文采用双曲正切激活函数:

$$\sigma(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (13)$$

假定神经网络的输入变量为 X , 输出变量为 Y , 神经网络的待识别参数 $\theta = [w, b]$, 输入层和输出层之间的关系可表示为:

$$Y = \mathcal{N}(X; \theta) \quad (14)$$

式中, $\mathcal{N}(\cdot; \theta)$ 为参数为 θ 的神经网络算子。

对于有监督的学习,在给定相应的训练样本 $D = \{X_n, Y_n\}_{n=1}^m$ 后,采用 L-BFGS 优化算法^[33]对损失函数进行优化,最终得到神经网络的待识别参数 θ 的最优值。本文工作均基于 Python3.6 和 Tensorflow1.14 环境,在 PyCharm 中编译完成,计算机 CPU 为 Intel i5-10600K, GPU 为 Nvidia GTX 1050Ti。

2.1 PINN 数值求解

在第 2 节中已推导得到隧道开挖引起地表沉降的物理关系。隧道的位置参数、半径,以及地层的泊松比一般在地勘资料中会明确给出。在利

用 PINN 深度神经网络求解这一问题时, 假设地表监测点的位置为 x , 开挖面位置为 y , 与围岩位移因子相关的模型参数为 η , 内在的应力-应变关系可以表示为:

$$f(x, y, \eta) = 0 \quad (15)$$

除此之外, 控制方程的边界条件也需要满足。以 PINN 作为代理模型进行数值求解时, 损失函数包括数据驱动项 (边界条件项) 和物理信息项。其中, 数据驱动项与传统 DNN 的损失函数相同, 训练过程需要提供位置坐标及对应的位移值; 而物理信息项仅需要提供位置坐标进行训练, 无需对应的位移值, 物理关系通过自动微分后得到的控制方程进行约束。相对于传统的深度学习算法需要提供大量的输入和输出样本, PINN 改善了对大数量训练样本的依赖。损失函数的具体表示形式如下:




图5 PINN 数值计算与反演的网络架构示意图

Fig. 5 Diagram of a PINN for numerical calculation and identification

2.2 PINN 参数反演

PINN 除了在数值求解代理模型上表现出优越的性能外, 还具备了强大的参数反演能力^[27]。对于隧道开挖诱发地表沉降而言, 这个问题就变为: 隧道开挖后, 通过现场监测获得了掌子面位于不同位置处时监测断面的地表沉降值, 以此对未知的地层参数进行反演。换言之, 已知 $\{x\}$, $\{y\}$ 和 $\{u_0(x, y)\}$, 对未知的地层参数 (如弹性模量和泊松比) 进行反演求解。

PINN 反演过程的网络架构保持不变, 与正向过程不同的是, 反演过程是根据已知数据 (如位置坐标, 位移) 对未知的物理参数 (如地层参数) 进行反演识别。此时的损失函数仍包含数据驱动项和物理信息项, 表示为:

$$MSE = \frac{1}{N} \left(\sum_{i=1}^N |u_0(x^i, y^i) - u_0^i|^2 + \sum_{i=1}^N |f(x^i, y^i, \eta)|^2 \right) \quad (17)$$

式中, $u_0(x^i, y^i)$ 为沉降值 u_0 的训练样本集合。由于反演过程的位移值均已明确, 数据驱动项和物理

$$MSE = \frac{1}{N_m} \sum_{i=1}^{N_m} |u_0(x_m^i, y_m^i) - u_0^i|^2 + \frac{1}{N_n} \sum_{j=1}^{N_n} |f(x_n^j, y_n^j, \eta)|^2 \quad (16)$$

式中: 等号右侧第一项为数据驱动项, $\{x_m^i, y_m^i, u_0^i\}_{i=1}^{N_m}$ 为包含位置坐标和位移值的训练样本的集合, 采用随机采样的方式获得, 数据总量为 N_m ; 第二项为物理方程残差项, $\{x_n^j, y_n^j\}_{j=1}^{N_n}$ 为研究区域内的位置坐标, 由于不需要对应的位移值, 样本点可以直接通过拉丁超立方采样获取, 数据总量为 N_n 。损失函数的第二项也可以看作是正则化项, 确保神经网络在训练过程中满足相应的物理力学关系, 从而降低模型的复杂度, 提高模型的泛化能力。PINN 数值求解与参数反演的网络架构如图5所示。

信息项的训练样本不再分别进行采样, 统一采用随机取样的方式获得, 样本总数为 N 。

3 算例分析

本节将以两个算例分别探讨 PINN 的正向预测和反向识别能力。假设隧道所处的位置和场地如图6所示, 相应的隧道半径、地层泊松比以及位移参数也在图中给出。

3.1 算例1: PINN 求解隧道开挖引起地层变形

在2.1节中已就半无限空间隧道诱发沉降变形的问题进行了推导, 本节将采用 PINN 的方法对这一过程进行求解。依据式(8)和边界条件, PINN 需满足的物理关系总结为:

$$\begin{aligned} f_1(x, z) &= \sigma_{ij,j} - f_i, \\ f_2(x, z) &= \sigma_{ij} - \lambda \delta_{ij} \epsilon_{kk} - 2\mu \epsilon_{ij}, \\ f_3(x, z) &= \epsilon_{ij} - \frac{1}{2} (u_{i,j} + u_{j,i}), \\ \sigma_{xz}, \sigma_{zz}|_{z=0} &= 0, \quad \sigma_{xz}, u_x|_{x=0} &= 0 \end{aligned} \quad (18)$$




图 6 隧道位置及其他相关参数 /m

Fig. 6 Geometry and related parameters of a tunnel

损失函数表示为:


$$MSE = \frac{1}{N_u} \sum_{i=1}^{N_u} |u(x_u^i, z_u^i) - u^i|^2 + \frac{1}{N_v} \sum_{j=1}^{N_v} \left(\sum_{k=1}^3 |f_k(x_v^j, z_v^j)|^2 \right) \quad (19)$$

式中: $\{x_u^i, z_u^i, u^i\}_{i=1}^{N_u}$ 为边界点的训练样本集合; $\{x_v^j, z_v^j\}_{j=1}^{N_v}$ 为研究区域内的坐标点集合; N_u 和 N_v 为采样数量。 k 取值为 1~3, $f_k(x_v^j, z_v^j)$ 对应于式 (18) 中的物理控制方程。损失函数的第二项物理残差项负责表达物理关系, 仅需提供位置坐标进行训练。


图 5 给出了 PINN 数值计算与反演的网络架构示意图。以 PINN 求解地层位移时, 采用深度神经网络参数 $\hat{u}(x, z, w, b)$ 代替 $u(x, z)$ (位移项), $\hat{\delta}(x, z, w, b)$ 代替 $\delta(x, z)$ (应力项), 然后利用自动微分求解应力-应变分量后得到深度神经网络参数 $\hat{f}(x, z, w, b)$, 进而代替 $f(x, z)$ 。无论权重 w 和偏差 b 取值如何, 参数 $\hat{u}(x, z, w, b)$, $\hat{\delta}(x, z, w, b)$ 和 $\hat{f}(x, z, w, b)$ 总是需要满足式 (18) 所规定的物理关系。在训练过程中, 给定训练样本和位置坐标, 通过最小化损失函数, 神经网络试图找到“正确的”权重 w^* 和偏差 b^* , 从而尽可能地使预测数据和残差微分方程与真实值相吻合。经过不断地训练和迭代, PINN 得到的预测值将逐渐逼近真实解。

图 7 给出了 PINN 地层沉降计算结果与解析解的对比, 其坐标与图 2 所示的 (x, z) 半无限空间相一致。PINN 在洞周边界上取 $N_u = 150$ 个训练样本 (x^i, z^i, u^i) , 采用随机取样的方式得到; 同时在研究区域内采用拉丁超立方采样生成了 $N_v = 1500$ 个笛卡尔坐标 (x^j, z^j) 。PINN 深度神经网络设置 6 个隐含层, 每层包含 40 个神经元, 所有神经元之间采用全连接的方式进行连接, 采用双曲正切激活函


数, 损失函数为均方差函数。由计算结果可知, PINN 的预测结果基本完全还原了解析解, 而训练样本仅用了 150 个。作为对比, 图 8 给出了传统 DNN 的计算结果。在训练样本和网络结构完全相同的情况下, DNN 得到的预测结果与实际值偏差非常大, 这表明 PINN 的预测能力相较于传统 DNN 进步显著, 体现了 PINN 强大的泛化性能。



(a) PINN预测值



(b) Verruijt-Booker准确值



(c) 地表沉降预测值与准确值对比

图 7 PINN 地层沉降预测结果

Fig. 7 Predicted results of vertical ground movements by PINN

3.2 算例 2: 基于地层变形反演地层参数

PINN 可以基于数据驱动对未知的物理参数进行识别, 这是 PINN 相对于其他深度学习方法所独有的优势。在此, 将 4.1 节的问题反置, 假定弹性模量 E 和泊松比 ν 是未知的参数, 利用 PINN 对其值进行反演。神经网络架构和参数与前节图 5 所示的框架保持一致, 损失函数为:





图8 DNN 地层沉降预测结果

Fig. 8 Predicted results of vertical ground movements by DNN

$$MSE = \frac{1}{N} \left[\sum_{i=1}^N |u(x_u^i, z_u^i) - u^i|^2 + \sum_{i=1}^N \left(\sum_{k=1}^3 |f_k(x_u^i, z_u^i)|^2 \right) \right] \quad (20)$$

研究区域内采用随机取样选取 $N = 500$ 个训练样本 (x^i, z^i, u^i) 。

反演得到的地层沉降场如图 9(a) 所示, 反演结果和准确值吻合较好; 图 9(b) 中地表沉降的反演值与准确值基本完全一致。表 1 对弹性模量 E 和泊松比 ν 的反演值及误差进行了总结。可以看出, PINN 可以准确地反演出未知参数, E 和 ν 的反演误差分别为 0.18% 和 0.24%, 反演结果保持了较高的精度。需要说明的是, 该算例初步探讨了 PINN 在应对未知物理参数的反演问题上所具备的潜力。实际工程中, 盾构穿越地层情况复杂, 利用 PINN 对复杂地层参数反演是需要深入研究的课题。

4 工程应用

实际工程中, 盾构隧道施工诱发的地表变形随开挖面掘进位置的不同而变化。如第 1 节中所述, Verruijt-Booker 解提供了半无限空间隧道开挖诱发地层变形的物理力学基础, 其应力-应变关系可以作为 PINN 模型的控制方程。在 PINN 模型的基础上, 增加一个并行的 DNN 框架对 Verruijt-





图9 PINN 地层沉降反演结果

Fig. 9 Identified results of vertical ground movements by PINN

表1 反演参数

Table 1 Identified parameters

参数	反演值	实际值	误差/(%)
弹性模量 E	10.018 05	10	0.18
泊松比 ν	0.200 48	0.2	0.24

Booker 解的围岩位移因子与开挖面掘进位置的关系进行预测^[34], 并与 PINN 模型相耦合, 即可搭建起地表沉降与开挖面掘进位置的关联。PINN 工程应用的网络架构如图 10 所示。

4.1 工程案例

4.1.1 工程案例 1

案例 1 的工程背景基于 WAN 等^[35]所述的伦敦地铁盾构隧道项目, 工程基本概况如图 11 所示。开挖面在不同位置处时某监测断面的地表沉降实测数据如图 12 所示, 其中: x 为监测点与隧道中线的水平间距; y 为开挖面与监测断面间距。

基于图 10 所示的 PINN 架构和所述的工程应用流程, 以 $y \leq 21.6$ m 的地表沉降实测数据为训练数据 (共计 100 个样本点), 置入 PINN 深度神经网络 (8×30) 中进行训练, 对开挖面位于 31.8 m、35.6 m 和 51.6 m 处的地表沉降值进行预测。作为对比, 给出了相同训练样本和网络架构下 DNN 的预测结果。最大地表沉降值的预测结果如图 13 所




图 10 PINN 工程应用的网络架构示意图
Fig. 10 Diagram of a PINN for the engineering application





图 11 工程概况 /m
Fig. 11 Project profile



注: y 为开挖面与监测断面间距
图 12 工程案例 1 实测数据
Fig. 12 Measured data of case 1

示, 误差如表 2 所示。可以看出, PINN 的预测结果保持了较高的精度, 最大误差仅为 1.81%, 而 DNN 的最大误差为 12.59%, 且随着与监测断面距离的增大, DNN 的预测误差呈逐渐增大的趋势。




图 13 地表沉降值预测结果对比
Fig. 13 Comparison of the predicted surface settlements

表 2 最大地表沉降值预测结果			
Table 2 Predicted results of the maximum surface settlement			
最大地表沉降值/mm	开挖面与监测断面的间距y/m		
	31.8 m	35.6 m	51.6 m
PINN	8.04	8.16	8.13
DNN	7.36	7.35	7.24
实测值	8.04	8.26	8.28
误差/(%)	PINN	0.04	1.81
	DNN	8.40	10.98

为了进一步比较 PINN 和 DNN 的预测结果, 给出了开挖面距监测断面 31.8 m、35.6 m 和 51.6 m

时地表沉降曲线的预测结果,如图 14 和图 15 所示。对比结果表明, PINN 基本可以完全还原地表沉降槽,在靠近和远离隧道中线的位置, PINN 的预测值与实测值均吻合很好,且开挖面处于不同位置时均保持了较高的预测精度。而 DNN 的预测结果与实测地表沉降曲线存在十分明显的偏差,特别是在开挖面与监测断面间距较大的位置 ($y = 51.6 \text{ m}$)。




图 14 PINN 预测值与实测值对比

Fig. 14 Comparison of the predicted results by a PINN and measured results




图 15 DNN 预测值与实测值对比

Fig. 15 Comparison of the predicted results by a DNN and measured results

在原训练样本的基础上增加 $y = 31.8 \text{ m}$ 、 35.6 m 时的实测数据 (共计 140 个样本点) 作为新的训练样本置入 DNN 中进行训练, 此时 DNN 的预测结果如图 16 所示。可以看出, DNN 在训练样本充足的情况下也可以得到合理的预测结果, 这也进一步说明了 PINN 在引入物理机制的约束后, 明显降低了对训练样本数据量的需求。

由上述对比结果可以看出, 开挖面位于不同

位置时, PINN 预测得到的地表沉降曲线均显著优于 DNN 的预测结果, 表明物理驱动的配置使 PINN 的外推泛化能力得到了显著的提高。PINN 克服了传统 DNN 算法内插能力强, 外推性能差的缺点, 展现了较强的外推泛化能力, 这为预测盾构隧道施工过程中地表沉降的变化趋势提供了有力的手段。





图 16 DNN 预测值与实测值对比 (训练样本总数 140)

Fig. 16 Comparison of predicted results by a DNN and measured results (Training data: 140)

4.1.2 工程案例 2

案例 2 为北京地铁 14 号线“方~十”区间盾构隧道工程, 该区间隧道开挖地层总体均一性较好, 属于北京地区具有代表性的地层; 某监测断面隧道上覆土层厚度为 10.8 m, 隧道内径 6.0 m, 上覆土体以黏性土为主, 夹杂少许粉细砂性土, E 和 ν 的取值分别为 13 MPa 和 0.25, 监测得到的地表沉降数据如图 17 所示^[36], x 、 y 的物理意义与图 12 相同。



注: y 为开挖面与监测断面间距

图 17 工程案例 2 实测数据

Fig. 17 Measured data of case 2

同样基于图 10 所示的 PINN 工程应用的网络架构, 以 $y = 0$ m、8.4 m、21 m 处的实测数据为训练样本, 预测 $y = 30$ m 处的地表沉降曲线, 训练样本的总数共 27 个点。PINN 和 DNN 的预测结果与实测值的对比分别如图 18 和图 19 所示。可

以看出, PINN 预测得到的地表沉降曲线基本与实测值完全吻合; 同等配置的 DNN 可以预测得到地表沉降曲线的变化趋势, 但得到的沉降值均明显大于实测值。整体上看, DNN 可以在一定程度上捕捉地表沉降的变化规律, 但预测结果的准确程度明显低于 PINN, 体现了 PINN 模型优秀的外推泛化性能。




图 18 PINN 预测值与实测值对比

Fig. 18 Comparison of predicted results by a PINN and measured results




图 19 DNN 预测值与实测值对比

Fig. 19 Comparison of predicted results by a DNN and measured results

4.2 工程应用流程

基于上述预测过程, 对 PINN 的工程应用流程进行总结, 如图 20 所示。PINN 基于工程施工前期一定数量的监测数据对后续施工过程的地表沉降趋势进行预估, 为使模型预测结果保持较高的精度, 可以依据工程所需的误差控制要求, 在一定的时间节点进行误差校准和样本更新, 从而保证 PINN 准确预测施工周期内地表沉降的变化趋势。

依据该流程, 预测得到工程案例 1 的地表沉降场如图 21 所示。可以看出, 预测得到的地表沉降场与实测沉降值保持了高度一致, 在临近隧道






图 20 PINN 模型的工程应用流程

Fig. 20 Diagram of the engineering application of a PINN model



(a) 实测值



(b) PINN预测值

图 21 地表沉降场

Fig. 21 Surface settlement field

中线附近沉降值较大, 远离隧道中线处沉降值逐渐变小; 随着开挖面与监测断面间距的增大, 沉降值有先增大后趋向平稳的趋势。PINN 的预测结果基本可以准确地还原实测的地表沉降场, 该方法有助于提升盾构隧道施工过程中地表沉降控制的智慧化水平, 为工程的潜在风险提供预警。

5 结论

深度学习与传统学科交叉为现有问题的解答提供了新的方法和途径。本文提出了一种基于数据-物理双驱动的物理信息深度神经网络 (PINN) 模型以预测盾构施工过程中诱发的地表沉降。首先, 将 Verruijt-Booker 解的控制方程耦合至 DNN 框架中, 得到耦合物理机制的 PINN 框架; 在此基础上, 以并行的 DNN 框架预测 Verruijt-Booker 解的围岩位移因子, 建立地表变形与开挖面空间位置的关联。构建的 PINN 模型可以基于部分工程实测数据对后续施工过程中诱发的地表沉降进行准确预测。通过算例分析与工程实例分析验证了提出方法的合理性, 所得结论如下:

(1) 在数据稀疏的情况下, PINN 得益于物理驱动的优势, 预测精度显著优于传统的 DNN 算法; 同时物理驱动机制使 PINN 具备了良好的反演性能。

(2) 数据-物理双驱动的 PINN 模型可以有效预测盾构隧道施工过程中诱发的地表沉降, 物理机理的引入改善了传统 DNN 算法过于依赖大量数据驱动的弊端, 提高了模型的外推泛化能力, 显著降低了对训练样本的需求。

(3) 提出的 PINN 模型可以实现基于施工前期一定数量的实测数据以及阶段性的误差控制, 准确预测盾构隧道后续施工过程中开挖面处于不同位置时监测断面的地表沉降曲线。该方法有助于提高盾构隧道施工过程中地表沉降安全控制的智慧化水平, 可为工程的潜在风险和施工决策提供预警和指导。

参考文献:

- [1] PECK R B. Deep excavations and tunnelling in soft ground [C]// Proceedings of the 7th International Conference on Soil Mechanics and Foundation Engineering. Mexico City: State of the Art Report, 1969: 225 - 290.
- [2] 朱才辉, 李宁. 隧道施工诱发地表沉降估算方法及其规

- 律分析[J]. *岩土力学*, 2016, 37(增刊 2): 533 — 542.
- ZHU Caihui, LI Ning. Estimation method and laws analysis of surface settlement due to tunnelling [J]. *Rock and Soil Mechanics*, 2016, 37(Suppl 2): 533 — 542. (in Chinese)
- [3] 张治国, 杨轩, 赵其华, 等. 盾构隧道开挖引起地层位移计算理论的对比与修正[J]. *岩土工程学报*, 2016, 38(增刊 2): 272 — 279.
- ZHANG Zhiguo, YANG Xuan, ZHAO Qihua, et al. Assessment and modification of traditional methods for ground displacements induced by shield tunnelling [J]. *Chinese Journal of Geotechnical Engineering*, 2016, 38(Suppl 2): 272 — 279. (in Chinese)
- [4] SAGASETA C. Analysis of undrained soil deformation due to ground loss [J]. *Géotechnique*, 1987, 37(3): 301 — 320.
- [5] VERRUIJTT A, BOOKER J R. Surface settlements due to deformation of a tunnel in an elastic half plane [J]. *Géotechnique*, 1998, 46(5): 753 — 756.
- [6] 魏纲, 张世民, 齐静静, 等. 盾构隧道施工引起的地面变形计算方法研究[J]. *岩石力学与工程学报*, 2006(增刊 1): 3317 — 3323.
- WEI Gang, ZHANG Shimin, QI Jingjing, et al. Study on calculation method of ground deformation induced by shield tunnel construction [J]. *Chinese Journal of Rock Mechanics and Engineering*, 2006(Suppl 1): 3317 — 3323. (in Chinese)
- [7] 韩凯航, 张成平, 王梦恕. 浅埋隧道围岩应力及位移的显式解析解[J]. *岩土工程学报*, 2014, 36(12): 2253 — 2259.
- HAN Kaihang, ZHANG Chengping, WANG Mengshu. Explicit analytical solutions for stress and displacement of surrounding rock in shallow tunnels [J]. *Chinese Journal of Geotechnical Engineering*, 2014, 36(12): 2253 — 2259. (in Chinese)
- [8] JIN D L, SHEN X, YUAN D J. Theoretical analysis of three-dimensional ground displacements induced by shield tunnelling [J]. *Applied Mathematical Modelling*, 2020, 79: 85 — 105.
- [9] MAYNAR M M, RODRIGUEZ L M. Predicted versus measured soil movements induced by shield tunnelling in the Madrid Metro extension [J]. *Canadian Geotechnical Journal*, 2005, 42(4): 1160 — 1172.
- [10] 陈仁朋, 王诚杰, 鲁立, 等. 开挖对地铁盾构隧道影响及控制措施[J]. *工程力学*, 2017, 34(12): 1 — 13.
- CHEN Renpeng, WANG Chengjie, LU Li, et al. Influence of excavation on exist metro shield tunnel and control measures [J]. *Engineering Mechanics*, 2017, 34(12): 1 — 13. (in Chinese)
- [11] 彭华, 杨志蔚, 曹全, 等. 盾构下穿铁路碎石道床沉降规律及施工参数控制[J]. *工程力学*, 2019, 36(增刊 1): 222 — 228.
- PENG Hua, YANG Zhiwei, CAO Quan, et al. The settlement law of railway ballast beds traversed by a shield tunnel and the control of shield construction parameters [J]. *Engineering Mechanics*, 2019, 36(Suppl 1): 222 — 228. (in Chinese)
- [12] 梁东, 金浩, 肖军华, 等. 软土地区侧压损失对盾构隧道受力及变形的影响[J]. *工程力学*, 2019, 36(5): 148 — 156, 175.
- LIANG Dong, JIN Hao, XIAO Junhua, et al. Influence of lateral pressure loss on the force and deformation of shield tunnel in soft soil area [J]. *Engineering Mechanics*, 2019, 36(5): 148 — 156, 175. (in Chinese)
- [13] XIANG Y, LIU H, ZHANG W, et al. Application of transparent soil model test and DEM simulation in study of tunnel failure mechanism [J]. *Tunnelling and Underground Space Technology*, 2018, 74: 178 — 184.
- [14] CHEN R P, ZHANG P, KANG X, et al. Prediction of maximum surface settlement caused by earth pressure balance (EPB) shield tunnelling with ANN methods [J]. *Soils and Foundations*, 2019, 59(2): 284 — 295.
- [15] FREITAG S, CAO B T, NINIĆ J, et al. Recurrent neural networks and proper orthogonal decomposition with interval data for real-time predictions of mechanised tunnelling processes [J]. *Computers and Structures*, 2018, 207: 258 — 273.
- [16] ZHANG W, LI H, WU C, et al. Soft computing approach for prediction of surface settlement induced by earth pressure balance shield tunneling [J]. *Underground Space*, 2021, 6(4): 353 — 363.
- [17] SHEIL B B, SURYASENTANA S K, MOONEY M A, et al. Machine learning to inform tunnelling operations: Recent advances and future trends [J]. *Proceedings of the Institution of Civil Engineers-Smart Infrastructure and Construction*, 2020, 173(4): 74 — 95.
- [18] ZHANG W, PHOON K K. Editorial for advances and applications of deep learning and soft computing in geotechnical underground engineering [J]. *Journal of Rock Mechanics and Geotechnical Engineering*, 2022, 14(3): 671 — 673.
- [19] LI J, LI P, GUO D, et al. Advanced prediction of tunnel boring machine performance based on big data [J]. *Geoscience Frontiers*, 2021, 12(1): 331 — 338.
- [20] ZHANG W, CHING J, GOH A, et al. Big data and machine learning in geoscience and geoengineering: Introduction [J]. *Geoscience Frontiers*, 2021, 12(1): 331 — 338.
- [21] WANG H, ZHANG L, YIN K, et al. Landslide identification using machine learning [J]. *Geoscience Frontiers*, 2021, 12(1): 351 — 364.
- [22] ZHANG W, LI H, LI Y, et al. Application of deep learning algorithms in geotechnical engineering: A short critical review [J]. *Artificial Intelligence Review*, 2021, 54: 5633 — 5673.
- [23] 林荣安, 孙钰丰, 戴振华, 等. 基于RS-SVR的上软下硬地层盾构施工地表沉降预测[J]. *中国公路学报*, 2018, 31(11): 130 — 137.

- LIN Rongan, SUN Yufeng, DAI Zhenhua, et al. Predicting for ground surface settlement induced by shield tunnelling in upper-soft and lower-hard ground based on RS-SVR [J]. *China Journal of Highway and Transport*, 2018, 31(11): 130 — 137. (in Chinese)
- [24] 陈仁朋, 戴田, 张品, 等. 基于机器学习算法的盾构掘进地表沉降预测方法[J]. *湖南大学学报 (自然科学版)*, 2021, 48(7): 111 — 118.
- CHEN Renpeng, DAI Tian, ZHANG Pin, et al. Prediction method of tunnelling-induced settlement using machine learning algorithms [J]. *Journal of Hunan University (Natural Sciences)*, 2021, 48(7): 111 — 118. (in Chinese)
- [25] 陈仁朋, 邹聂, 吴怀娜, 等. 盾构掘进地表沉降机器学习预测与控制研究综述[J]. *华中科技大学学报 (自然科学版)*, 2022, 50(8): 56 — 65.
- CHEN Renpeng, ZOU Nie, WU Huaina, et al. State of the art and prospect of prediction and control for surface settlement caused by shield tunneling based on machine learning [J]. *Journal of Huazhong University of Science and Technology (Natural Science Edition)*, 2022, 50(8): 56 — 65. (in Chinese)
- [26] RAISSI M, PERDIKARIS P, KARNIADAKIS G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations [J]. *Journal of Computational Physics*, 2019, 378: 686 — 707.
- [27] RAISSI M, YAZDANI A, KARNIADAKIS G E. Hidden fluid mechanics: Learning velocity and pressure fields from flow visualizations [J]. *Science*, 2020, 367(6481): 1026 — 1030.
- [28] 李想, 严子铭, 柳占立. 机器学习与计算力学的结合及应用初探[J]. *科学通报*, 2019, 64(7): 635 — 648.
- LI Xiang, YAN Ziming, LIU Zhanli. Combination and application of machine learning and computational mechanics [J]. *Chinese Science Bulletin*, 2019, 64(7): 635 — 648. (in Chinese)
- [29] 张亦知, 程诚, 范钊彤, 等. 基于物理知识约束的数据驱动式湍流模型修正及槽道湍流计算验证[J]. *航空学报*, 2020, 41(3): 119 — 128.
- ZHANG Yizhi, CHENG Cheng, FAN Yitong, et al. Data-driven correction of turbulence model with physics knowledge constrains in channel flow [J]. *Acta Aeronautica et Astronautica Sinica*, 2020, 41(3): 119 — 128. (in Chinese)
- [30] 余海岁, 周国庆, 赵光思, 等. 岩土介质小孔扩张理论[M]. 北京: 科学出版社, 2013.
- YU Haisui, ZHOU Guoqing, ZHAO Guangsi, et al. Cavity expansion methods in geomechanics [M]. Beijing: Science Press, 2013. (in Chinese)
- [31] 周小文, 吴宏伟. 用于估计多隧道开挖地面沉降的解析解(英文)[J]. *岩土工程学报*, 2007, 29(11): 1703 — 1710.
- ZHOU Xiaowen, NG C W W. Analytical solution for estimating surface settlements induced by multiple tunnel excavation (in English) [J]. *Chinese Journal of Geotechnical Engineering*, 2007, 29(11): 1703 — 1710. (in Chinese)
- [32] PARK K H. Analytical solution for tunnelling-induced ground movement in clays [J]. *Tunnelling and Underground Space Technology*, 2005, 20(3): 249 — 261.
- [33] LIU D C, NOCEDAL J. On the limited memory BFGS method for large scale optimization [J]. *Mathematical Programming*, 1989, 45(1): 503 — 528.
- [34] RAO C, SUN H, LIU Y. Physics informed deep learning for computational elastodynamics without labeled data [J]. *Journal of Engineering Mechanics*, 2021, 147(8): 04021043.
- [35] WAN M S P, STANDING J R, POTTS D M, et al. Measured short-term ground surface response to EPBM tunnelling in London clay [J]. *Géotechnique*, 2017, 67(5): 420 — 445.
- [36] 潘苗. 盾构施工全过程引起的土体扰动与分层沉降特性研究 [D]. 北京: 中国矿业大学, 2016.
- PAN Zhuo. Study on soil disturbance and its classified settlement due to EPB TBM excavation [D]. Beijing: China University of Mining & Technology, 2016. (in Chinese)